TP évalué — Analyse de données ferroviaires avec PySpark

Objectifs

Ce TP a pour objectif d'évaluer votre capacité à utiliser Apache Spark avec Python pour :

- charger et explorer un jeu de données ;
- sélectionner et filtrer des données ;
- créer de nouvelles colonnes ;
- effectuer des agrégations ;
- utiliser l'API DataFrame ;
- utiliser Spark SQL ;
- construire et interpréter des analyses à partir des données.

Les résultats demandés doivent être affichés dans le notebook.

---

1. Présentation des données

Une société spécialisée dans l'analyse des transports souhaite étudier les trajets réalisés sur un réseau ferroviaire.

Vous disposez du fichier :

trains.csv

Chaque ligne représente un trajet ferroviaire.

Colonne	Description
`trip_id`	Identifiant du trajet
`date`	Date du trajet
`departure_station`	Gare de départ
`arrival_station`	Gare d'arrivée

`company`	Compagnie ferroviaire
`train_type`	Type de train
`distance_km`	Distance du trajet en kilomètres
`duration_min`	Durée réelle du trajet en minutes
`passengers`	Nombre de passagers
`delay_min`	Retard à l'arrivée en minutes
`cancelled`	Trajet annulé : `Yes` ou `No`

Partie A — Découverte et manipulation des données

Exercice 1 — Chargement

Charger le fichier `trains.csv` dans un DataFrame nommé :

trains

Le fichier possède une ligne d'en-tête. Les types des colonnes doivent être déterminés automatiquement par Spark.

Afficher :

- les 10 premières lignes ;
- le schéma du DataFrame ;
- le nombre total de trajets.

Exercice 2 — Sélection

Afficher uniquement les colonnes suivantes :

departure_station

arrival_station
distance_km
duration_min
delay_min

Afficher les 20 premières lignes du résultat.

Exercice 3 — Valeurs distinctes

Afficher :

1. les différentes gares de départ ;
2. les différentes compagnies ;
3. les différents types de trains.

Les résultats devront être triés par ordre alphabétique.

Exercice 4 — Filtrage

Afficher les trajets qui respectent simultanément les trois conditions suivantes :

- départ depuis `Paris` ;
- distance supérieure à 300 km ;
- trajet non annulé.

Afficher uniquement :

trip_id
departure_station
arrival_station
train_type
distance_km

Partie B — Premières analyses

Exercice 5 — Statistiques générales

En considérant uniquement les trajets **non annulés**, calculer :

- la distance minimale ;

- la distance maximale ;
- la distance moyenne ;
- la durée moyenne ;
- le retard moyen.

Les moyennes doivent être arrondies à **deux chiffres après la virgule**.

Utiliser des noms de colonnes explicites dans le résultat.

Exercice 6 — Les retards les plus importants

Afficher les **10 trajets ayant subi les retards les plus importants**.

Afficher uniquement :

- trip_id
- departure_station
- arrival_station
- train_type
- delay_min

Le trajet ayant le retard le plus important doit apparaître en premier.

Exercice 7 — Annulations

Calculer séparément le nombre de trajets :

- annulés ;
- non annulés.

Présenter le résultat sous la forme d'un tableau.

Exercice 8 — Classification des retards

Créer une nouvelle colonne appelée delayLevel en utilisant les règles suivantes :

Retard	`delayLevel`
0 à 5 minutes	`On time`

plus de 5 à 15 minutes	`Small delay`
plus de 15 à 30 minutes	`Medium delay`
plus de 30 minutes	`Large delay`

Calculer ensuite le nombre de trajets appartenant à chaque catégorie.

Pour cette analyse, ne pas prendre en compte les trajets annulés.

Partie C — Analyse des gares

La société souhaite maintenant comparer l'activité des différentes gares.

Exercice 9 — Activité par gare

Pour chaque **gare de départ**, produire un tableau contenant :

- le nombre de trajets ;
- le nombre total de passagers ;
- la distance moyenne parcourue ;
- le retard moyen.

Utiliser les alias suivants :

- numberTrips
- totalPassengers
- avgDistance
- avgDelay

Les moyennes doivent être arrondies à deux chiffres après la virgule.

Ordonner les résultats par nombre de trajets décroissant.

Les trajets annulés ne doivent pas être pris en compte.

Exercice 10 — Fréquentation des gares

À partir des données, déterminer :

1. les **5 gares de départ ayant transporté le plus de passagers** ;
2. les **5 gares ayant enregistré le plus de trajets au départ** ;
3. les **5 gares ayant le retard moyen le plus élevé**.

Pour chacune de ces analyses, afficher les valeurs permettant de justifier le classement.

Les trajets annulés ne doivent pas être pris en compte.

Exercice 11 — Interprétation

À partir des résultats de l'exercice précédent, répondre aux questions suivantes :

- Les gares ayant le plus grand nombre de trajets sont-elles également celles transportant le plus de passagers ?
- Les gares les plus fréquentées sont-elles celles qui présentent les retards moyens les plus élevés ?

Justifier les réponses avec des valeurs obtenues dans vos calculs.

Partie D — Analyse des lignes ferroviaires

Dans cette partie, une **ligne ferroviaire** est définie par la combinaison :

departure_station + arrival_station

Par exemple :

Paris → Lyon et Lyon → Paris sont considérées comme **deux lignes différentes**.

Exercice 12 — Statistiques par ligne

Pour chaque ligne ferroviaire, calculer :

- le nombre de trajets ;
- le nombre total de passagers ;
- le retard moyen ;
- le retard maximum.

Utiliser les alias :

- numberTrips

- totalPassengers
- avgDelay
- maxDelay

Ne prendre en compte que les trajets non annulés.

Exercice 13 — Comparaison des lignes

Produire deux classements :

Classement A : les 10 lignes ayant transporté le plus grand nombre total de passagers.

Classement B : les 10 lignes ayant le retard moyen le plus élevé.

Afficher les informations nécessaires à l'interprétation de chaque classement.

Exercice 14 — Fiabilité de l'analyse

Un retard moyen élevé sur une ligne comportant très peu de trajets peut être difficile à interpréter.

Refaire le classement des lignes selon leur retard moyen en ne conservant que les lignes ayant réalisé **au moins 30 trajets non annulés**.

Afficher les 10 premières lignes du nouveau classement.

Comparer brièvement ce résultat avec celui de l'exercice 13.

Partie E — Analyse suite

Exercice 15 — Analyse des types de trains

Pour chaque type de train, calculer :

- le nombre de trajets non annulés ;
- la distance moyenne ;
- la durée moyenne ;
- le retard moyen ;
- le nombre total de passagers.

Les moyennes doivent être arrondies à deux chiffres après la virgule.

Exercice 16 — Types de trains et retards

À l'aide d'une requête contenant notamment GROUP BY et HAVING afficher uniquement les types de trains dont le **retard moyen est supérieur à 10 minutes**.

Les trajets annulés ne doivent pas être pris en compte.

Exercice 17 — Analyse des compagnies

Pour chaque compagnie, calculer :

- le nombre total de trajets ;
- le nombre de trajets annulés ;
- le nombre total de passagers ;
- le retard moyen des trajets non annulés.

Ordonner le résultat par nombre total de trajets décroissant.

Exercice 18 — Compagnies et types de trains

Pour chaque combinaison company + train_type calculer :

- le nombre de trajets ;
- le nombre total de passagers ;
- le retard moyen.

Afficher les **10 combinaisons ayant transporté le plus grand nombre de passagers**.

Partie F — Étude de synthèse

Exercice 19 — Indicateur de ponctualité

On considère qu'un trajet est **en retard** lorsque delay_min > 15

Pour chaque gare de départ, calculer :

- `numberTrips` : nombre de trajets non annulés ;
- `totalPassengers` : nombre total de passagers ;
- `avgDelay` : retard moyen ;
- `maxDelay` : retard maximum ;
- `delayedTrips` : nombre de trajets ayant plus de 15 minutes de retard.

Calculer ensuite : delayRate = delayedTrips / numberTrips × 100

`delayRate` représente le pourcentage de trajets ayant plus de 15 minutes de retard.

Arrondir `avgDelay` et `delayRate` à deux chiffres après la virgule.

Afficher les gares par `delayRate` décroissant.

Exercice 20 — Rapport sur les lignes

Produire un rapport pour chaque ligne ferroviaire contenant :

Indicateur	Alias
Nombre de trajets	`numberTrips`
Nombre total de passagers	`totalPassengers`
Nombre moyen de passagers	`avgPassengers`
Durée moyenne	`avgDuration`
Retard moyen	`avgDelay`
Retard maximum	`maxDelay`

Ne prendre en compte que les trajets non annulés.

Ne conserver que les lignes possédant au moins **30 trajets**.

Ordonner le résultat par nombre total de passagers décroissant.

Exercice 21 — Analyse finale

À partir de l'ensemble des résultats obtenus, rédiger une conclusion de **10 à 15 lignes affichée dans un print de python**.

Votre analyse devra notamment répondre aux questions suivantes :

1. Quelles sont les gares concentrant le plus grand nombre de passagers ?
2. Quelles sont les lignes les plus fréquentées ?
3. Quelles gares rencontrent le plus de problèmes de ponctualité ?
4. Quelles lignes présentent les retards moyens les plus importants ?
5. Les lignes les plus fréquentées sont-elles nécessairement celles ayant le plus de retard ?
6. Quels résultats devraient, selon vous, être examinés en priorité par la société ?

Toutes les conclusions doivent être justifiées par des résultats calculés avec Spark.

Consignes de rendu

Le travail doit être réalisé dans **un notebook Databricks qui sera le rendu**.

Le notebook doit pouvoir être exécuté dans l'ordre, du début à la fin.

Pour les parties A à F, utiliser au moins une fois l'API **DataFrame PySpark** et au moins une fois **Spark SQL avec** `spark.sql()`.